

电信客户流失因素识别与挽留策略优化

队伍编号：023

队员姓名：杨张福 刘亚微 胡欣怡

2026 年 7 月 19 日

摘 要

问题背景：（简要说明问题背景和要解决的问题）

建模方法：（说明用了哪些模型、算法）

主要结果：（列出关键数值结果）

模型评价：（模型的优点和验证结果）

关键词：关键词 1；关键词 2；关键词 3；关键词 4；关键词 5

目录

1	引言	3
1.1	问题背景	3
1.2	问题重述	3
1.3	本文工作概述	3
2	总体分析	4
2.1	问题分析	4
2.2	数据说明	4
2.3	整体建模流程	5
3	模型假设	5
4	符号说明	5
5	模型的建立与求解	6
5.1	数据处理与 EDA	6
5.1.1	数据预处理	6
5.1.2	流失客户特征探索	7
5.1.3	初步结论	11
6	模型检验	12
6.1	灵敏度分析	12
6.2	误差分析	12
6.3	鲁棒性检验（可选）	13
6.4	模型对比（可选）	13
7	模型评价	13
7.1	模型优点	13
7.2	模型缺点	13
8	模型的改进与推广	13
8.1	模型改进方向	13
8.2	模型推广	14

1 引言

1.1 问题背景

在电信行业中，获取新客户的成本通常为保留老客户的 5 至 7 倍，因此客户流失的有效管控直接关系到企业的可持续发展。某电信运营商近一年内客户流失率由 18% 攀升至 26%，亟需识别导致客户流失的关键因素并制定针对性的挽留策略。

本研究基于该运营商提供的 7043 名客户历史数据，涵盖人口统计学特征、账户服务信息及流失状态记录。通过数据清洗与探索性分析，建立分类预测模型，结合模型可解释性方法识别核心流失因子，最终根据不同风险层级制定差异化的客户挽留方案，为运营商降低客户流失率提供数据驱动的决策支持。

1.2 问题重述

本文主要通过以下三个递进问题展开分析：

问题一：流失客户特征画像。对原始数据进行预处理和探索性分析，通过可视化手段对比流失客户与未流失客户在各特征维度上的差异，识别潜在的高相关流失因子。

问题二：流失预测与关键因子识别。构建多种分类模型（逻辑回归、随机森林、XGBoost）对客户流失概率进行预测，以 AUC 和 F1-score 为评价指标进行模型对比与优选。在此基础上运用 SHAP 方法量化各特征的贡献度，确定前五位关键流失因子。

问题三：客户分层与差异化挽留策略。基于预测流失概率将客户划分为低、中、高三三个风险层级，针对不同层级设计差异化的挽留方案，并结合客户生命周期价值（CLTV）估算策略的预期投入产出比。

1.3 本文工作概述

本文综合运用了探索性数据分析、机器学习分类建模和 SHAP 可解释性分析等方法，建立了客户流失预测模型与分层挽留框架，主要工作如下：

- 针对问题一：**对原始数据进行缺失值检查和数据类型修复，剔除 CustomerID、Count、Country 等无用特征，保留 30 个可用变量。通过计算整体流失率（26.54%）发现类别不平衡特征。对在网时长（Tenure Months）、月消费金额（Monthly Charges）等数值特征绘制分组直方图与箱线图，对合同类型（Contract）、互联网服务类型（Internet Service）等分类特征绘制流失率对比柱状图，结合相关性热力图，综合识别出在网时长和合同期限为区分流失客户最显著的特征。
- 针对问题二：**在特征工程基础上，分别构建逻辑回归、随机森林和 XGBoost 三种分类模型，以 AUC 和 F1-score 为核心指标进行对比评价。对最优模型使用 SHAP 方法进行全局和局部可解释性分析，量化各特征对流失预测的贡献度，提取前五位关键流失因子，并从业务角度进行解读。
- 针对问题三：**根据最优模型的预测流失概率，将客户划分为低风险、中风险和高风险三个层级。针对不同层级客户的行为特征设计差异化的挽留策略：对高风险客户

给予年付合同优惠和专属客服跟进，对低风险客户维持常规关怀。结合客户生命周期价值估算策略的预期投入产出比，论证方案的经济可行性。

最终，通过多模型对比和 SHAP 可解释性分析验证了模型结果的可靠性与可解释性，为运营商提供了切实可行的客户流失管控方案。

2 总体分析

2.1 问题分析

问题一分析：该问题本质为数据探索与特征分析问题。核心目标是在无先验假设的条件下，通过对原始数据的统计分析和可视化呈现，构建流失客户群体的特征画像。需重点关注两方面：一是数据质量——是否存在缺失值、异常值及类型不一致等影响建模的问题；二是特征区分度——哪些变量在流失与未流失两组客户之间呈现显著差异。可采用分组统计、分布对比图、相关性分析等手段对数据进行系统探索。

问题二分析：该问题本质为二分类建模与模型可解释问题。在问题一筛选出的高区分度特征基础上，构建从客户特征映射到流失概率的预测模型。分类模型的选择需兼顾预测精度与可解释性：逻辑回归作为线性基准模型具有天然可解释性，随机森林能有效捕捉非线性交互关系，XGBoost 在结构化数据上通常取得最优精度。模型评估需考虑类别不平衡特征，采用 AUC 和 F1-score 等对不平衡数据鲁棒的指标。此外，需引入 SHAP 等可解释性分析方法，将模型输出的“黑箱”决策转化为各特征的量化贡献，为业务决策提供可理解的依据。

问题三分析：该问题本质为策略优化与投入产出评估问题。基于问题二中模型输出的连续流失概率，可对客户进行风险分层，将离散化的层级与客户生命周期价值（CLTV）结合，针对不同层级客户的行为特征设计差异化的挽留方案。方案需同时考虑预期效益（减少流失所挽回的收入）与实施成本（优惠力度、运营投入），从而评估策略的经济可行性。

2.2 数据说明

数据来源：题目附录文件 Telco_customer_churn.xlsx。

数据规模：共 7043 条客户记录，33 个特征变量，包含客户的人口统计学特征（性别、年龄、家庭状况）、账户服务信息（在网时长、合同类型、支付方式、服务开通情况）、费用信息（月消费、总消费、生命周期价值）以及是否流失的标签。

数据质量与预处理：经检查，数据整体无缺失值，其中 Total Charges 列初始为字符串类型，经转换后存在 11 处空值——均为在网时长为 0 的新客户（尚未产生消费），已统一填充为 0。剔除 CustomerID、Count、Country 三个无信息量列，剩余 30 个可用特征，全部 7043 条记录完整可用。

目标变量分布：流失客户 1869 人（占比 26.54%），未流失客户 5174 人（占比 73.46%），呈现一定程度的类别不平衡，后续建模需采取加权或采样策略加以应对。

2.3 整体建模流程

本文的整体建模流程如图 1 所示。



图 1 整体建模流程图

首先进行数据预处理与探索性分析，识别数据质量问题和关键特征；然后进行特征工程（类别编码、数值标准化、训练测试集划分），分别训练逻辑回归、随机森林、XGBoost 三种分类模型并通过 AUC 与 F1-score 进行对比优选；对最优模型进行 SHAP 可解释性分析，提取关键流失因子；最后基于模型输出的流失概率进行客户分层，制定差异化挽留策略并估算投入产出比。

3 模型假设

为简化实际问题、聚焦核心矛盾，本文在建模过程中做出以下合理假设：

- (1) 假设一名称：（假设内容）假设理由是...，此假设的合理性在于...
- (2) 假设二名称：（假设内容）假设理由是...，此假设的合理性在于...
- (3) 假设三名称：（假设内容）假设理由是...，此假设的合理性在于...
- (4) 假设四名称：（假设内容）假设理由是...，此假设的合理性在于...
- (5) 假设五名称：（假设内容）假设理由是...，此假设的合理性在于...

以上假设贯穿全文，在后续各章中不再赘述。若有特定章节需要单独说明的假设，在该章节中另行声明。

4 符号说明

本文中使用的数学符号及其含义统一说明如下。符号按字母顺序排列，同一符号在不同章节中的含义保持一致。

表 1 符号说明表

符号	单位	含义
N	–	样本总数 / 数据总量
M	–	指标数量 / 变量个数
x_i	–	第 i 个样本 / 自变量
y_i	–	第 i 个样本的因变量
w_j	–	第 j 个指标的权重
α	–	显著性水平 / 参数
β	–	回归系数 / 参数
R^2	–	拟合优度（决定系数）
ε	–	误差项 / 极小正数

注：对于仅在局部出现的符号，在各章节中单独说明，不列入上表。

5 模型的建立与求解

5.1 数据处理与 EDA

5.1.1 数据预处理

本文的来自题目附件 `Telco_customer_churn.xlsx`，包含了 7043 条客户数据记录，共 33 个字段，涵盖客户人口统计学信息、账户信息、服务订阅信息和流失标签。

本文首先利用 `pandas` 将 `Telco_customer_churn.xlsx` 文件转换为 `csv` 文件，以便后续对数据进行处理。接着本文读取了数据文件的基本信息，对数据进行了清洗，剔除了 `CustomerID`、`Count`、`Country` 三列。我们剔除这三列的依据是第一，`CustomerID` 作为唯一标识，与客户流失情况无关，无泛化预测能力；第二，`Count` 恒为 1，方差为 0，对区分客户无贡献；第三，`Country`，全部为 `United States`，无差异性，对模型无额外信息量。

其次，在完成数据清洗工作之后，本文发现 `Total Charges` 为字符串类型，不便于后续对数值数据的处理。于是，`Total Charges` 列的数据经 `pd.to_numeric` 转换后确认 11 条 `NaN` 记录。通过追溯发现这 11 条记录的 `Tenure Months` 均为 0（新客户尚未产生消费）；因此填充为 0，符合正常的业务逻辑。处理后全部 7043 行无缺失值。

最后，本文为了更加方便地识别各列数据的含义，对部分关键数据的列名，进行了中英翻译，提供列名对照表如表 2 所示。后续分析将统一使用中文名称。

表 2 关键变量名称对照表

变量类别	中文名称	原始列名	说明
目标变量	是否流失	Churn Value	1= 流失, 0= 未流失
(一) 时长与费用特征			
数值	在网时长	Tenure Months	单位: 月
数值	月消费金额	Monthly Charges	单位: 美元
数值	总消费金额	Total Charges	单位: 美元
数值	客户生命周期价值	CLTV	Customer Lifetime Value
(二) 合同与支付特征			
分类	合同类型	Contract	月付/一年/两年
分类	支付方式	Payment Method	共 4 种
二分类	是否无纸化账单	Paperless Billing	Yes / No
(三) 服务订阅特征			
多分类	互联网服务类型	Internet Service	DSL/Fiber optic/No
二分类	在线安全服务	Online Security	Yes/No/No internet
二分类	技术支持服务	Tech Support	Yes/No/No internet
(四) 人口与家庭特征			
二分类	是否老年人	Senior Citizen	Yes / No
二分类	是否有配偶	Partner	Yes / No
二分类	是否有家属	Dependents	Yes / No
(五) 其他说明			
文本	客户编号	CustomerID	无预测价值, 已剔除
数值	纬度	Latitude	与流失相关系数 <0.01
数值	经度	Longitude	与流失相关系数 <0.01

5.1.2 流失客户特征探索

整体流失率

本文首先对数据的整体客户流失情况, 进行了分析以了解各类别的分布特征。以 Churn Value 为分类依据, 统计得到客户流失 1869 人, 未流失客户 5174 人, 总客户 7043 人, 整体流失率为 26.54%, 如图 2 所示




图 2 整体流失率环形图

从分布比例来看，流失与未流失两类样本的比例约为 1:2.8，呈现一定程度的类别不均衡。这一比例虽然不属严重失衡（如 1:10 以上），但已足以对常规分类模型的训练过程产生影响——模型倾向于将多数类（未流失）识别得更好以降低整体损失，而牺牲对少数类（流失）的识别能力。例如，一个将所有样本都预测为“未流失”的简单模型也能获得 73.46% 的准确率，但这显然不能反映模型在实际业务中的价值。

针对上述问题，本文在后续建模中采取以下应对措施：一是在评价指标上，不采用对不平衡数据敏感的准确率（Accuracy），而采用 AUC（ROC 曲线下面积）和 F1-score 作为主要评价指标；二是在模型训练上，对逻辑回归设置 `class_weight='balanced'` 参数，使模型根据类别频率自动调整权重，强化对流失客户的关注。

整体流失率

其次，为考察流失客户与未流失客户在数值特征上的分布差异，本文选取了选取在网时长（Tenure Months）、月消费金额（Monthly Charges）和总消费金额（Total Charges）三个具有明确的业务含义的核心数值特征，分别绘制分组直方图与箱线图进行对比，如图 3 所示。

数值特征分布对比




图 3 数值特征分布对比图

本文通过对这三个特征的直方图和箱线图的分析，得到了这些特征与客户流失情况存在的关联如下：

在网时长：流失客户的分布高度集中于 0-10 个月的低在网时长区间，而未流失客户的分布较为均匀，覆盖 0-72 个月的全区间。箱线图显示两组中位数差距显著，说明在网时长是区分能力最强的数值特征——新客户是流失的高风险群体。

月消费金额：流失客户的月消费整体偏高，在 70-110 美元的高费区间聚集密度明显大于未流失客户。高消费客户对价格更为敏感，流失意愿相对更强。

总消费金额：流失客户的总消费明显偏低且呈左偏分布，但该差异主要源于在网时长长短导致的消费积累不足，属于在网时长的间接效应，其独立区分能力有限。

综合以上分析，在网时长是区分流失与未流失最有效的数值特征。

分类特征流失率对比

然后本文为考察分类变量各取值水平下的流失风险差异，选取合同类型、互联网服务类型、支付方式、是否老年人、是否有配偶、是否有家属、是否开通电话服务、是否无纸化账单共 8 个分类特征，分别统计各组流失率并绘制柱状图，如图 4 所示。

分类特征流失率对比




图 4 分类特征流失率对比图

本文结合图中反映的各个特征不同组别类型的流失率和流失人数，发现了各个特征的客户流失的特点如下：

合同类型 (Contract)：月付合同的流失率超过 40%，而一年合同约为 10%、两年合同约为 3%。合同期限的差异根本性地改变了客户流失的转换成本——月付客户可以随时解约，而年付和两年合同的客户通常承担了提前解约的违约金或已享受合约折扣，转换运营商的意愿显著降低。

互联网服务类型 (Internet Service)：光纤客户的流失率显著高于 DSL 客户和无互联网客户，可能与光纤服务的高月费有关——高消费群体对服务性价比的要求也更高。

支付方式 (Payment Method)：电子支票客户的流失率约为 45%，而银行自动转账、信用卡自动支付和邮寄支票三种方式的流失率均在 15%-20% 之间，表明支付方式与客户属性之间存在一定的关联性。

此外，有配偶或有家属的客户流失率低于独身客户（家庭绑定提高了离网成本），无纸化账单客户流失率高于纸质账单客户（无纸化账单客户更习惯线上操作，对运营商的服务切换成本感知较低，更容易比价和更换服务商），而是否老年人和是否开通电话服务对流失率的影响相对较小。

相关性热力图

最后，本文采用 Pearson 相关系数衡量各数值特征与流失之间的线性关联强度，相关系数的取值范围为 $[-1, 1]$ ，绝对值越接近 1 表示线性相关越强。本文据此计算了数值变量的相关系数矩阵，并以热力图形式呈现，如图 5 所示。




图 5 相关性热力图

通过热力图可以直观看出各特征与客户流失的相关程度。本文对相关系数的分析，得到以下发现：

在网时长：与流失的相关系数为 -0.352 ，在所有数值特征中绝对值最大，呈中等程度的负相关——在网时间越长，流失可能性越低，这与前文分析中“新客户是高危群体”的结论相一致。

月消费金额：与流失的相关系数为 $+0.193$ ，呈弱正相关——月消费越高的客户对服务性价比的要求也越高，流失意愿更强，这与分类特征分析中光纤客户流失率较高的发现互为印证。

总消费金额与 CLTV：与流失的相关系数分别为 -0.198 和 -0.127 ，均为弱负相关，方向符合预期。但值得注意的是，在网时长与总消费之间存在较强的正相关 ($r = 0.83$)，这是因为在网时间越长累计消费自然越高，说明两变量存在多重共线性，后续建模中可考虑择一保留。

地理特征：经度、纬度、邮编三个特征与流失的相关系数绝对值均小于 0.01 ，不具备线性预测价值，说明地理位置与客户的流失决策之间不存在明显的关联关系。

5.1.3 初步结论

综合上述探索性分析，可从以下维度刻画流失客户的典型特征：在合同层面，流失客户以月付合同为主，其流失率超过 40% ，远高于年付和两年合同客户；在在网时长层面，流失客户高度集中在在网 $0-10$ 个月的新客户群体，在网时长是与流失相关性最强的数值特征 ($r = -0.352$)；在消费层面，流失客户的月消费金额偏高，高消费群体对服

务性价比更为敏感，流失意愿更强；在家庭层面，无配偶、无家属的独身客户流失率高于有家庭绑定的客户，前者离网成本更低。

上述发现为下一节分类模型的建立提供了明确的方向——模型应重点纳入合同类型、在网时长、月消费金额等具有强区分能力的特征变量。

6 模型检验

6.1 灵敏度分析

（分析模型参数变化对结果的影响程度，识别敏感参数。）

为检验模型对关键参数的敏感程度，对参数 α 在 $[\alpha_0 - 50\%, \alpha_0 + 50\%]$ 范围内以 5% 步长进行扰动，观察模型输出的变化。结果如图 6 所示。




图 6 参数 α 的灵敏度分析

结果表明：当 α 在 $\pm 20\%$ 范围内波动时，模型输出的变化不超过 5%，说明模型对参数 α 不敏感，结果具有较好的稳定性。

6.2 误差分析

（若模型有预测/拟合功能，对比预测值与真实值的误差。）

采用均方根误差（RMSE）和平均绝对百分比误差（MAPE）作为评价指标：

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}, \quad \text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right| \times 100\% \quad (1)$$

表 3 模型误差指标

指标	数值	评价
RMSE	0.XXXX	误差较小，模型精度良好
MAPE	X.XX%	预测偏差在可接受范围内

6.3 鲁棒性检验（可选）

（通过蒙特卡洛模拟、K 折交叉验证、Bootstrap 等方法进一步验证模型稳定性。）

6.4 模型对比（可选）

（若有多个候选模型，从精确度、计算复杂度、可解释性等维度进行横向对比，说明所选模型的优势。）

7 模型评价

7.1 模型优点

1. 优点一：（描述）例如：模型假设合理，充分考虑了实际约束条件，具有较强的现实意义。
2. 优点二：（描述）例如：采用（某方法）进行求解，算法收敛速度快，计算效率高。
3. 优点三：（描述）例如：模型具有良好的可扩展性，可通过调整参数适应不同场景的需求。
4. 优点四：（描述）例如：经灵敏度分析和误差检验，模型结果稳定可靠。

7.2 模型缺点

1. 缺点一：（描述）例如：模型假设（某条）在极端情况下可能不完全成立，限制了模型的适用范围。
2. 缺点二：（描述）例如：求解过程中对初始值有一定依赖，不同初始值可能导致局部最优。
3. 缺点三：（描述）例如：模型仅考虑了（某些因素），未能纳入（其他因素）的影响。

8 模型的改进与推广

8.1 模型改进方向

（针对第 7 章中提到的模型缺点，提出相应的改进思路。）

1. 改进一：针对（某缺点），可考虑采用（某方法）替代原模型中的（某部分），以提高模型在（某方面）的表现。
2. 改进二：针对（某缺点），可将（某因素）纳入模型，构建更加全面的（多目标/多维度）模型。
3. 改进三：在求解算法方面，可尝试（某算法）以获得全局最优解，避免陷入局部最优。

8.2 模型推广

（说明本模型可以推广到哪些其他领域或应用场景。）

本文所建立的（模型名称）不仅适用于本文所研究的问题，还可以推广到以下场景：

- 1.（场景一）：在（某领域）中，可将模型稍加调整后应用于（某问题）。
- 2.（场景二）：本模型的（某核心方法）可作为通用框架，解决类似的（某类问题）。
- 3.（场景三）：结合（某技术/某方法），本模型可进一步拓展为（某更强大模型）。

参考文献

参考文献